CounterScene-3D：具有状态延续的原生素材空间评测

Yunfei Lu　　GPT-6.1-sol

English edition | 交互式基准展示

Abstract

本中文版本与英文主报告使用同一冻结数据、图表和评测口径。基准将可执行空间能力评估与面向学习的奖励诊断连接起来，优势在于真实状态延续、针对性捷径审计和可追溯的多维证据。CounterScene-3D 评测模型在观察变化后，通过可执行程序操作实际三维素材的能力。五类任务包含三十个开发实例、六十个有序操作。我们比较两个参测模型，独立检查几何与运动结果，使用 Astra 提供辅助视觉评分，并通过小模型 best-of-four 实验分析奖励信号。结果只适用于当前几何开发集，不代表真实机器人可靠性或分布外泛化。

1　基准设计与决策递进

研究基础方面，3DCodeVerse 提供可执行三维世界及执行、测量、视觉评审和修复闭环 [1]；BlenderGym 研究生成与验证预算 [2]，BlenderWorld 使用多视角任务级视觉准则 [3]。SceneScript 与 VoxPoser 分别提供结构化场景和空间行动背景 [4, 5]。我们的增量在于将真实跨阶段状态、针对性捷径对照、功能验收与奖励诊断组织成可复现的评测协议，而不是将已有混合评分或多轮修复宣称为首创。

空间评测需要同时观察视觉合理性与行动后果。我们保存观察、程序、实际执行状态、反馈和不可撤销提交，使模型在场景变化后保留既有成果的能力可以被直接审计。每类任务包含两个场景种子和 L1–L3 三个层级，共六个实例。各层级分别要求一、二、三个有序操作；A 类对应 k06、k14、k34。递进来自新的工作要求、观察更新与已完成工作的保留，而不是输入更长或在两个近似场景间反复切换。难度仍是经验问题，更多阶段不保证模型成功率严格下降。

A：搬移与恢复。第一阶段将工作台明显移到另一位置，并将台面物品暂放在原位置地面；第二阶段按原台面相对偏移恢复物品；第三阶段处理另一工作区，同时保留前面成果。评分检查明确目标、支撑和保留要求，只有无碰撞还不够。

B：逐步修复碰撞。每阶段只开放当前工作区，保留已修复区域与尚未开放区域。中间阶段允许明示的待修复问题，最终必须满足完整硬约束与可行软约束。模型须指认不可满足的软约束。固定 gold 后续方案失败不等于不存在其他可行后续方案。

C：变化视角下的重建。初始提供实际素材样例和标定的正、侧、俯视图。后续目标明显移动物体，并释放新的斜视观察，要求模型修正位置与允许的尺度，同时保留仍正确的结构。额外视角受查询预算限制；公开视角吻合并不能替代隐藏视角和物体中心误差检查。

D：连续操控。每阶段抓取不同物体、放到柜子上、释放并移动到后续位置。下一阶段继承实际末端关节和已释放物体的位置，已释放物体成为障碍。抓取失败不会自动搬动物体，释放位置来自实际执行的末端位置。模型还必须处理关节零点偏移。

E：误导反馈。逐步修复真实物理问题，同时面对错误通过、错误失败、遗漏、数值噪声或被隐藏的碰撞信息。模型可测量实际几何。几何修复与检查器故障诊断分别报告，未实际出现在冻结实例中的干扰类型不算已评测。

2　执行、约束与端到端验证

输出是受限 Python 的 build 函数，返回完整素材位姿或机械臂控制序列。解释器允许有界算术与集合操作，禁止导入、属性访问、文件和网络访问。公开参数不包含隐藏目标。素材身份固定，模型操作的是实际网格；包围盒不能替代展示或静态评估中的素材。

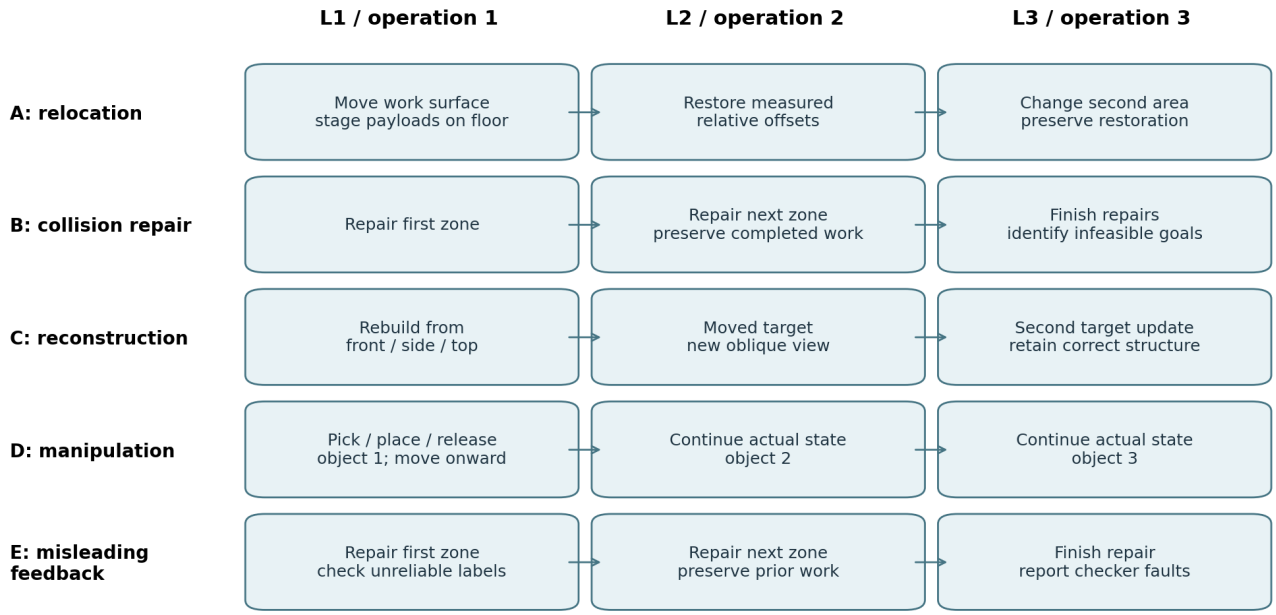


Figure 1: 五类任务的实际阶段依赖。后续操作必须保留此前成果。图中英文术语与主报告一致。

所有实例从内容绑定的阶段文件加载。Gold 通过实际执行验证硬约束、共同可行的软目标、支撑、边界、接触和穿模。捷径测试包括旧答案复用、仅更新固定物体坐标、忽略新观察和不适当复用早期运动方案。这些是具体反例与可行见证，并非对所有策略的完备证明。

搬移与重建目标变化的路径检查使用实际连通网格导出的包络。机械臂另外检查连续的臂、工具、携带物体、固定设施和已释放物体间净空、关节限制与抓放语义。包络重叠表示未能证明安全，不自动等于实际网格相交。该模型是运动学模型，不模拟摩擦、力闭合、扭矩或动态稳定性。静态修复任务主要评价端点，不能将其可视化误认为已验证运输路径。

严格整条轨迹成功要求每个必需阶段、当前约束和此前成果都正确。有效但错误的提交不可撤销，不能用一个正确末态抹去早期失败。C 还要求隐藏视角的逐物体平均轮廓 IoU 至少 0.8，且每个原生物体包围中心误差均不超过 0.05 米。平均值可能隐藏某个小物体的大误差，因此两项必须同时满足。D 必须满足连续有效性和实际事件顺序。

基础设施错误与模型失败分开。已确认响应精确重放而不重新生成，复用响应只计一次。程序字节与原生素材哈希保留身份。

3 参测协议与完整结果

参测模型为 GPT-6.1 Sol 与 Claude Opus 5.5，使用 medium reasoning，每个响应最多 8,000 输出 token，每个操作最多十四个动作。三十个实例乘两个模型形成六十条基础轨迹；固定 L3 面板为每类任务和每个模型再增加一次独立生成，共七十条。独立重复面板提供初步的生成变异证据，扩大种子与重复次数将进一步提高估计精度。新增探索实验完成五条反馈/视角对照，并与原始条件逐实例比较；另一个行政中断的 C 续跑单列，不计为模型失败。

全部七十条轨迹均具备有效基础设施证据。下表只汇总基础比较，每个任务和模型有六个实例。GPT 严格成功 26/30，Claude 为 24/30；这是开发集描述，而非普遍优劣结论。

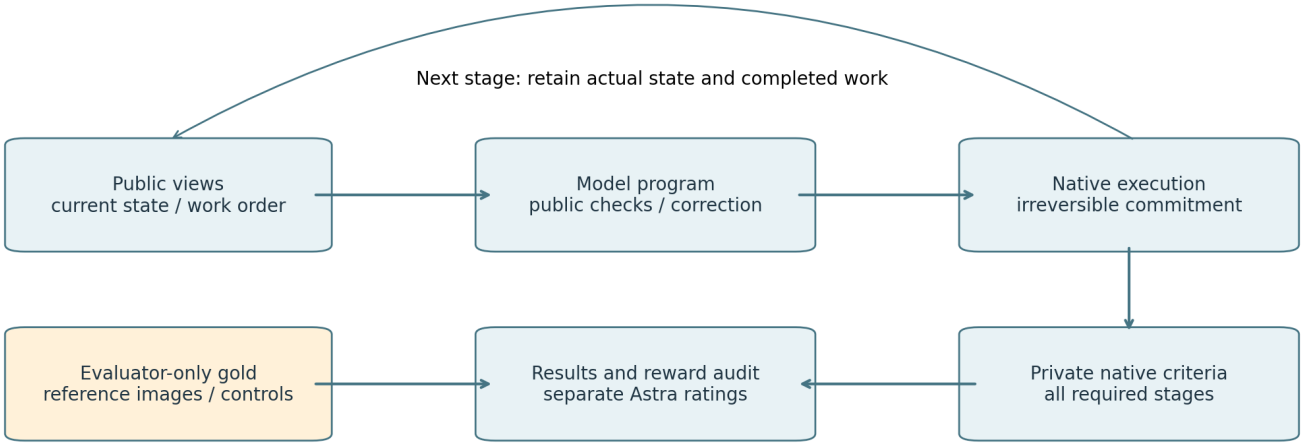


Figure 2: 评估流程：公开观察驱动模型行动；隐藏程序和度量目标仅由评估器使用；视觉评分不能覆盖执行检查。

任务	模型	样本	严格成功率	形状奖励
A	Claude	6	1.000	1.000
A	GPT	6	1.000	1.000
B	Claude	6	0.833	0.982
B	GPT	6	0.833	0.981
C	Claude	6	0.333	0.432
C	GPT	6	0.500	0.580
D	Claude	6	1.000	1.000
D	GPT	6	1.000	1.000
E	Claude	6	0.833	0.765
E	GPT	6	1.000	0.912

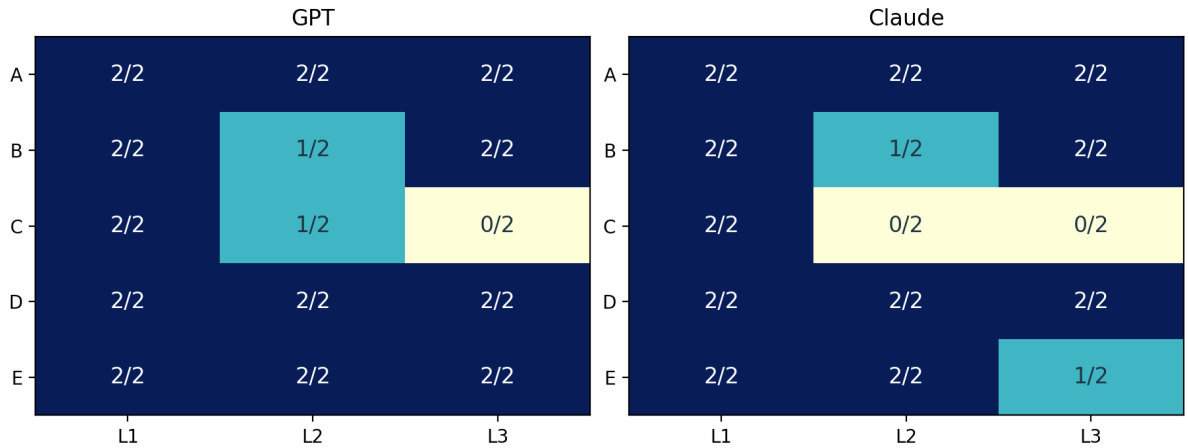


Figure 3: 每个格子对应两个种子的严格成功数。任务难度不是关于层级的简单单调排名。

反馈利用的改进空间。 B-L2-s0 中两个模型都在公开检查器报告硬约束失败后，提交未改变的程序。前一阶段成功，最终关系修复失败。这里能观察到的是未利用反馈修正，而不是模型的内部意图。

目标更新下的重建挑战。 C-L2-s0 中 Claude 第一阶段重建成功，目标变化后未通过隐藏视角与度量检查。第二阶段执行十三个动作，没有额外视角查询。不能据此推断额外查询必然解决问题。

多维验收的价值。 GPT 在 C-L2-s1 第一阶段通过轮廓与中心检查，却保留实际物理冲突；第二阶段成功仍不能消

除早期失败。Claude 在该实例也有物理冲突，并额外存在度量问题。

修复与诊断分离。 E-L3-s1 中 GPT 满足 26/26 个原生关系，识别 2/4 个检查器故障；Claude 满足 25/26，识别 0/4。几何成功不代表完整诊断。分类允许一条轨迹出现多个问题，工具错误也可能出现在最终成功的轨迹中。



Figure 4: C-L3-s0 的真实参考与模型渲染。IoU 来自隐藏视角；通过视觉阈值不保证物体中心、物理检查或整条轨迹通过。

4 奖励诊断与对强化学习的启发

Rubrics as Rewards 与 AdvancedIF/RIFL 支持显式准则及奖励聚合的研究方向 [6, 7]；VideoEdit 对细粒度信用分配的研究启发我们同时检查过程反馈和真实任务结果 [8]。对模型评审偏差的已有研究也支持保留匿名准则、重复评分和覆盖率 [9]。

每阶段确定性奖励要求物理许可的功能成功。形状奖励对适用的功能、约束、可行软目标、保留、诊断、操作、重建和运动分量取等权平均。整条轨迹按必需阶段数平均，未执行阶段记零；不适用维度不当成零填入。未获许可的物理问题或移动锁定对象会触发门控。运动经过某个路标不能抵消路径不安全。

校准包含三十个实例、四类输出和三次重复，共 360 次数值评分。Gold、空输出、旧答案或静止输出、安全中间解测试已声明的排序，全部通过；固定数值重算的最大奖励方差为零。全部六十个有序 gold 阶段也取得满分，包括允许暂留指定问题的中间阶段。另取每类任务一个 GPT 输出，使用任务包独立执行第二次，完整阶段评分一致，配对奖励方差为零。这个五输出、每输出两次的原生重跑子集，不代表所有输出或所有平台稳定。

十组独立生成面板的形状奖励总体方差介于 0 与 0.2223。这与重算同一输出的方差不同，样本量很小。Astra 固定图像重复评分的样本方差介于 0 与 0.0093，控制样本平均可评分覆盖率为 0.906；不确定项为缺失，而非失败。五类任务的弱排序均满足，且 gold 均严格高于旧答案，但平分仍削弱区分度。七个功能失败的基础输出获得至少 0.75 的辅助视觉分数，说明视觉合理性不能替代执行检查。

Astra 只作为匿名视觉辅助评估器，比较参考与候选的身份布局、可见支撑、可见净空和可见目标吻合。D 使用代表性轨迹中段帧；静态图像无法证明整条路径、终点事件或抓放正确性。同一提供方与其中一个参测模型有家族关联，也需要警惕潜在偏差，不能用单个评估器估计因果偏差。

小模型实验使用量化 Qwen3.5:9B（Q4_K_M），每个任务两个开发实例、每池四个固定种子候选，共十池四十个候选。选择只依据公开工具奖励，再独立审计隐藏质量；失败和相同分数均保留，平分选首个候选。平均隐藏质量由首个候选的 0 提高到选择后的 0.2，改善仅来自 A。E 的选择后公开分数为 0.3、隐藏质量为 0；若未比首个候选提高公开分数，就不能宣称优化学会了利用漏洞。这是 best-of-four 推理实验，不是 RL 训练或泛化证明。

各维度分析分别讨论空程序、素材替换、接触容差、保留低编辑成本却放弃目标、信任错误标签、轮廓掩盖度量误差，以及用漂亮端点隐藏不安全路径。对应分类为难以利用、可利用但有边界、或软性视觉判断。原生网格、联合中心条件、操作目标、锁定状态和事件检查针对具体攻击，但容差和观察不完整仍存在边界。

这些证据为面向学习的奖励研究提供了具体起点：固定原生安全和功能验收，分别研究课程设计、过程反馈密度与候选选择。后续扩大场景、种子和自适应优化规模，再通过短期 RL 训练测量能力收益，可进一步验证这些设计启发。

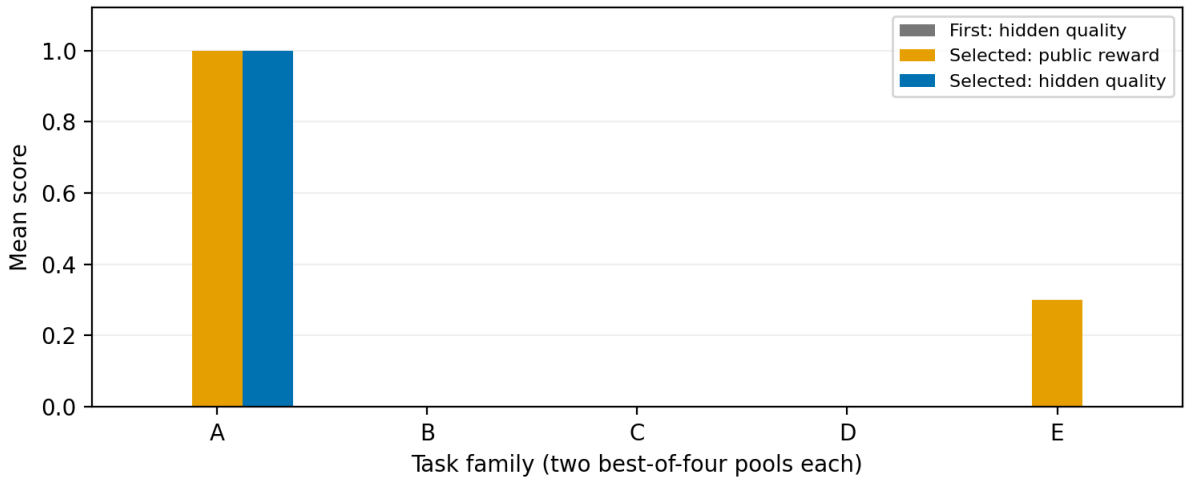


Figure 5: 公开奖励负责选择，隐藏质量负责独立审计。只有 A 在该小样本中改善，其他任务仍为零隐藏质量。

新增面向学习的诊断。 原始候选池的均匀随机选择期望隐藏质量为 0.075，公开奖励选择后为 0.20，增益集中在 A。这提供了局部选择收益的正向证据。五条新增前沿模型对照进一步展示行为差异：GPT 在 B-L2-s0 的仅执行反馈条件成功，结构化/标量条件未完成；C-L2-s0 的固定与主动视角均成功，调用数分别为 10 和 26。这些事后选例的观察适合指导更大规模的配对实验，不直接作为一般因果结论。

小模型新增八组等预算实验，覆盖 C、D、两阶段 A 和 E，比较独立采样与公开反馈修正，每阶段三个候选。格式适配器只转换模型给出的数值，不提供隐藏答案。30 个候选中 26 个进入原生评分，八条轨迹均未达到严格完成，29 个候选实际奖励为零。这将接口可执行性与几何规划能力分开，明确了课程学习与反馈密度的研究切入点。

另两组 D 单例直接反馈实际形状奖励，各复用一个起点并增加两次生成；包括从模型自己的首个公开可执行方案开始的设置。两组均未提高奖励或完成任务。另一个安全 D 候选获得 0.4 部分奖励但尚未完成转运。保留这些差别有助于研究如何把局部进展转化为完整能力，训练收益仍需扩展实验验证。

逐维度可利用性分析。 下表将攻击方式与对应检查明确配对。“有边界”表示可利用但受约束；分类适用于当前测试域。任务包和研究数据保留具体示例与缓解措施。

维度	分类	攻击方式；对应检查
程序与素材身份	难以利用	非法程序、替换素材；受限解释与身份检查。
物理与接触	有边界	利用接触容差；实际网格与未知状态拒绝通过。
操作目标	有边界	无碰撞但未完成操作；显式目标验收。
软约束与诊断	有边界	虚报不可满足；联合见证与声明核对。
度量重建	有边界	轮廓相似但中心错误；联合度量验收。
轨迹与事件	有边界	只满足端点；连续检查与实际释放。
编辑与保留	有边界	不修改以降低代价；目标与保留验收。
检查器一致性	有边界	依赖错误通过；几何与诊断分别审计。
视觉质量	软性判断	遮挡或外观；辅助角色与覆盖率。
目标访问	有边界	读取隐藏文件；受限公开接口。

5 复现、局限与改进方向

任务包将公开提示与图像同评估器目标、gold 和评分代码分离。原生素材保留许可与内容哈希。无需提供方访问或模型权重即可重算数值；原生重放需要 Python 与外部 Blender。单命令核对奖励、表格、生成方差、视觉评分和候选选择，另可执行全部保留动作。五个任务包的 gold 均独立验证可解。报告和网页使用同源数值，不把基础设施缺失算为模型零分。

公开开发证据包含有序事件哈希、实际代码修改提交与英文提示派生稿。完整可见事件日志另留本地；内部推理与配置数据排除，私密正文不公开。网页区分 gold、模型实际执行和未执行阶段。轨迹来自实际关节状态，播放速度仅用于说明。

覆盖范围。两个世界种子和开发模板限制推断；后续应保留未见场景与更多素材目录，并扩展独立重复，再讨论模型排名。

物理近似。保守包络可能误拒可行路径，几何支撑不等于动态稳定。应先用独立网格测试校准误拒，再加入力、摩擦和抓取动力学。

视觉评分。单一模型家族并非人工真值，D 中段图片也不证明最终事件。应增加匿名独立评估器、人工抽查和短运动片段，检验事件敏感的判断。

奖励有效性。等权分量是设计选择；应比较不同权重，进行更长的自适应攻击，并用留出质量审计。十个开发候选池不能证明 RL 稳定性，gold 重放也不证明规则完备。

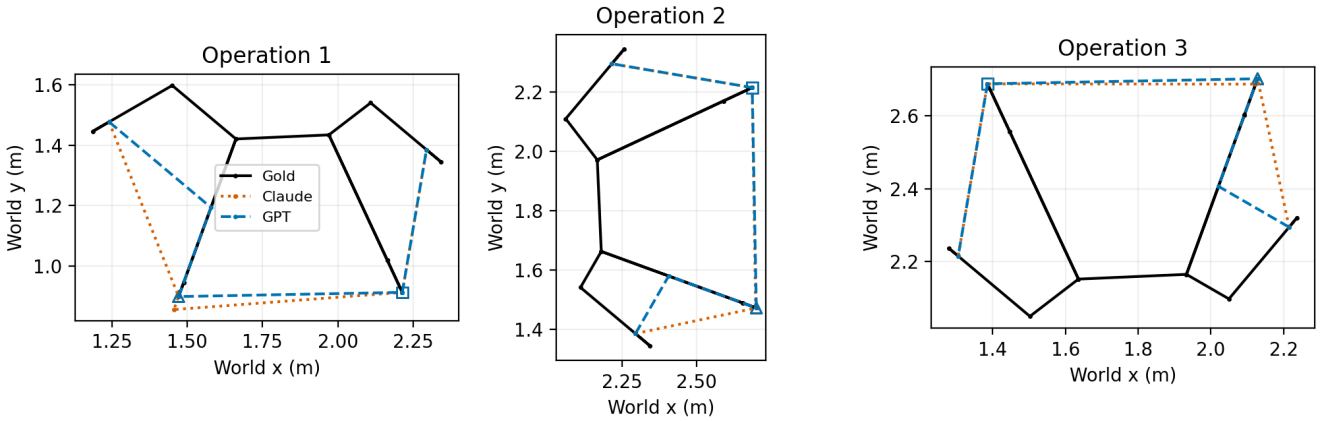


Figure 6: D-L3-s0 的实际末端轨迹关键帧，比较 gold、GPT 与 Claude。三角标记抓取，方形标记释放；连续安全依赖独立运动学证书，而非图上线段。

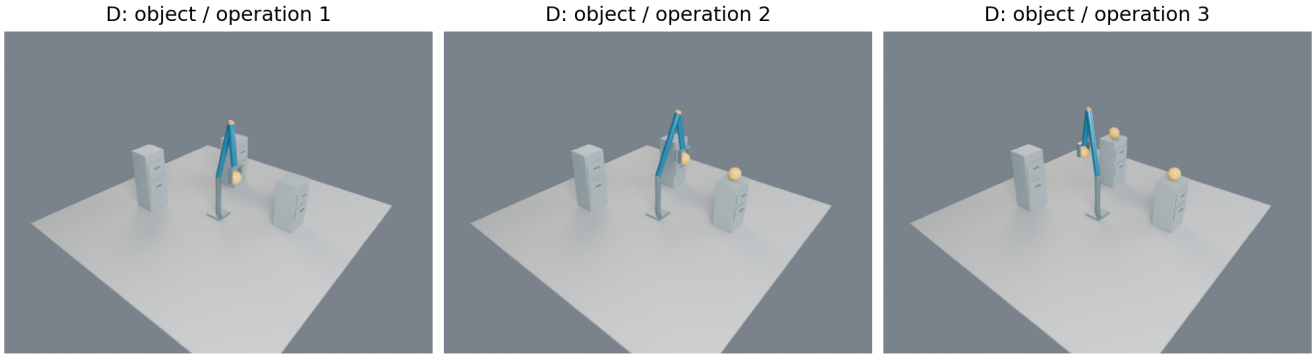


Figure 7: D 的连续 gold 操作中段帧。后续画面保留先前释放物体；终点与事件语义须结合完整三维轨迹和原生检查。

6 更多基准样例

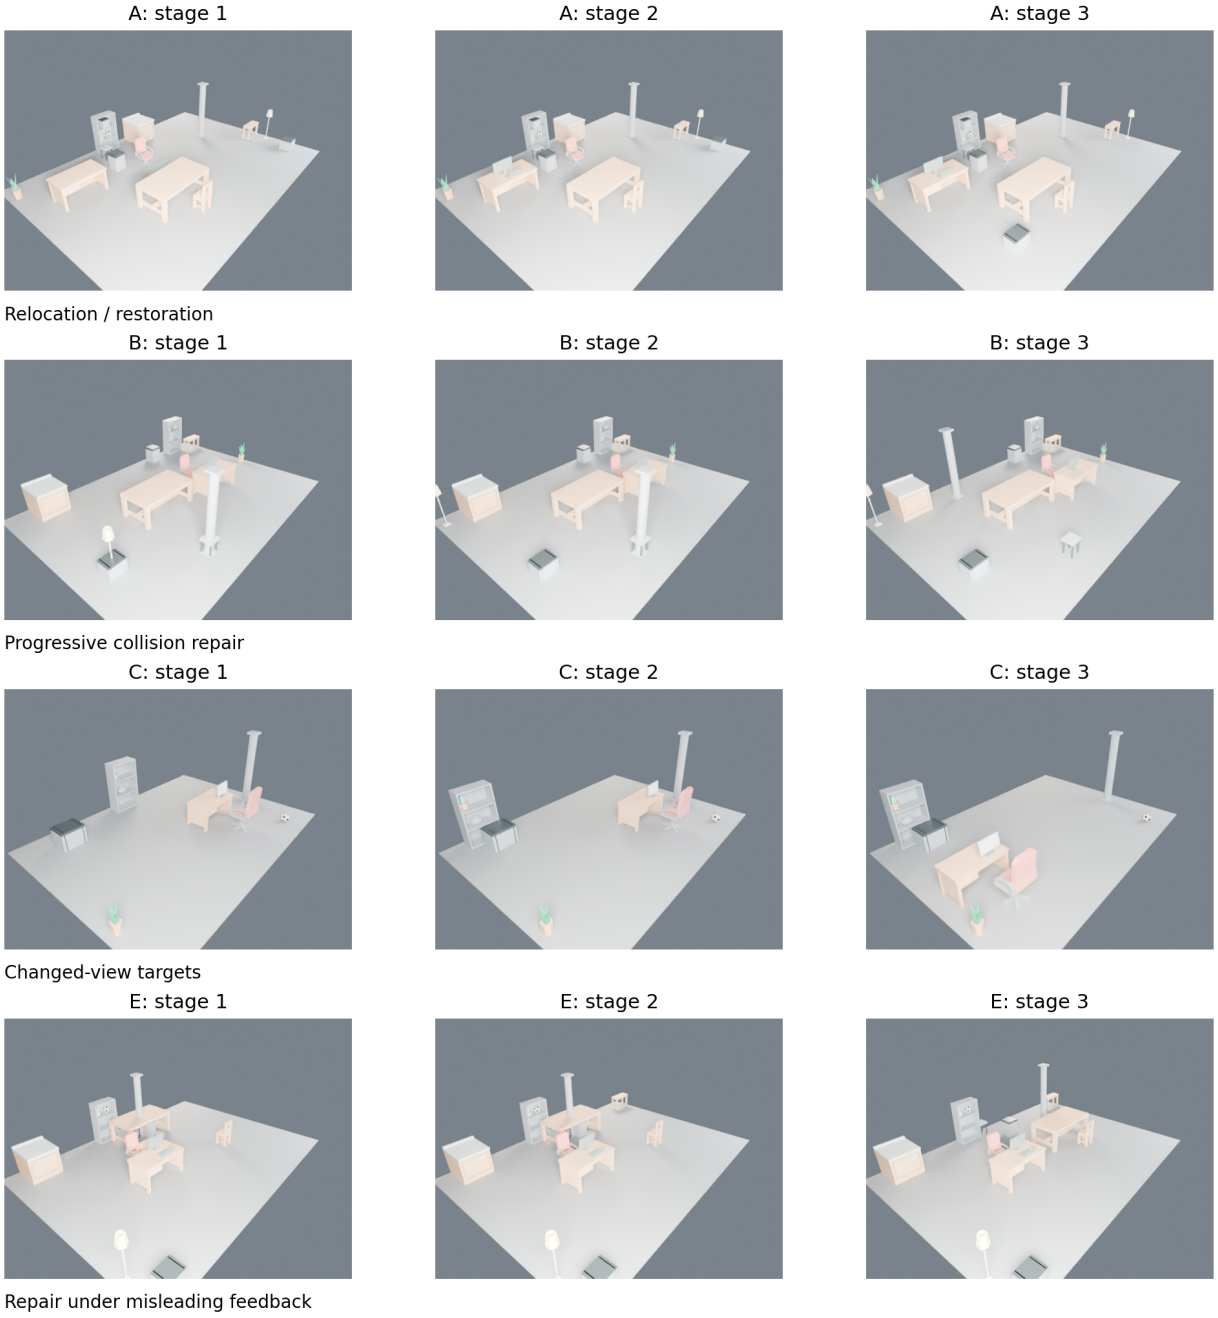


Figure 8: A、B、C、E 各三阶段的真实 gold 样例，使用种子零。B/E 中间阶段有意保留已声明的未来问题。这些是可行参考见证，不是模型输出。

References

[1] Gao et al. 3DCodeVerse: Exploring 3D Worlds as Code. 2026 preprint. https://arxiv.org/abs/2610.22341. Official harness: https://github.com/gaoypeng/3dcodeverse/tree/main/harness.

[2] Gu et al. BlenderGym: Benchmarking Foundational Model Systems for Graphics Editing. CVPR, 2025. https://arxiv.org/abs/2504.01786.

[3] Fang et al. BlenderWorld: Benchmarking Visual Agents for 3D Creation from Real-World References. 2026 preprint. https://arxiv.org/abs/2610.23986.

[4] Avetisyan et al. SceneScript: Reconstructing Scenes With An Autoregressive Structured Language Model. 2024. https://arxiv.org/abs/2403.13064.

[5] Huang et al. VoxPoser: Composable 3D Value Maps for Robotic Manipulation with Language Models. 2023. https://arxiv.org/abs/2307.05973.

[6] Gunjal et al. Rubrics as Rewards: Reinforcement Learning Beyond Verifiable Domains. 2025 preprint. https://arxiv.org/abs/2507.17746.

[7] He et al. AdvancedIF: Rubric-Based Benchmarking and Reinforcement Learning for Advancing LLM Instruction Following. 2025 preprint. https://arxiv.org/abs/2511.10507.

[8] Zhao et al. When Fine-Grained Credit Assignment Helps and Hurts: Multimodal Agentic Reinforcement Learning through Video Editing. 2026 preprint. https://arxiv.org/abs/2610.35497.

[9] Zheng et al. Judging LLM-as-a-Judge with MT-Bench and Chatbot Arena. NeurIPS Datasets and Benchmarks, 2023. https://arxiv.org/abs/2306.05685.